

Predicting Cardiac Diseases in Children

CC4072: Foundations of Data Science

Inês Dutra

2025-26

Rui Santos - up202109728



Overview

- Problem Definition
- Raw Data
- Preprocessing
- Análise
- Conclusões

Problem Definition

- **Ranking de features:** um dos principais objetivos determinar a 'feature importance' sobre as features que são mais preditivas de patologias cardíacas em crianças.
- **Modelos preditivos:** construir e avaliar a performance de modelos preditivos capazes de distinguir pacientes com a patologia cardíaca ('Anormal') e sem a patologia cardíaca ('Normal').
- **Contexto dos dados:** os dados provêm de registos anonimizados de crianças, do Real Hospital Português (RHP), no Brasil. As variáveis de input incluem dados demográficos (idade, género), medidas físicas (peso, altura, IMC) e indicadores clínicos (pressão arterial, sons cardíacos, sopros).
- **Objetivo técnico:** realizar uma pipeline de análise/tratamento dos dados para poder no final ter um dataset 'útil' e com informação relevante e válida, para utilizar nos modelos preditivos.

Raw data – Variable Description

- Classificar cada atributo consoante o seu tipo:

- **Categórico**

- Nominal
 - = , !=
- Ordinal
 - = , != , < , >

- **Numérico**

- Interval
 - < , > , + , -
- Ratio
 - < , > , + , = , * , /

Atributo	Descrição	Nominal	Ordinal	Interval	Ratio
ID	anonymized patient ID	X			
Peso	patient weight				X
Altura	patient height				X
IMC	body mass index (BMI)				X
Atendimento	date of visit		X		
DN	birth date		X		
IDADE	age				X
Convenio	health care insurance	X			
PULSOS	pulses	X			
PA SISTOLICA	systolic blood pressure (SBP)			X	
PA DIASTOLICA	diastolic blood pressure (DBP)			X	
PPA	result SBP/DBP	X			
NORMAL x ANORMAL	absence or presence of pathology	X			
B2	type of the second heart sound	X			
SOPRO	murmur type	X			
FC	cardiac frequency			X	
HDA1	histoy of disease 1	X			
HDA2	histoy of disease 2 (other history)	X			
SEXO	patient gender	X			
MOTIVO1	first reason for being forwarded to the cardiology clinic	X			
MOTIVO2	second reason for being forwarded to the cardiology clinic	X			


Raw data - Análise preliminar

- Avaliação inicial para compreender a estrutura e qualidade da raw data
- Identificação de falhas críticas no dataset, nomeadamente:
 - Inconsistências e duplicados
 - Outliers e valores fisicamente impossíveis
 - Elevado volume de missing values
- Utilização de gráficos para detetar ruído e padrões anómalos
- Renomeação e uniformização das colunas para facilitar o tratamento subsequente

Raw data - Análise preliminar (Sumários)


- **Dimensão do Dataset:** 17873 registros de pacientes, cada um descrito com 21 features
- **Inconsistência de Tipos:** algumas variáveis, ao ser importadas, obtém o tipo errado
 - E.g. Frequência cardíaca (FC) reconhecida como objeto em vez de ser numérica
- **Missing values:** temos um grande volume de missing values, tendo variáveis com taxas que chegam até 43% de missing values
- **Target feature:**
 - Contém erros de Labeling ('Normais' em vez de 'Normal' e 'anormal' em vez de 'Anormal')
 - Predominância de casos sem patologia cardíaca ('Normal') em comparação aos casos que tem a patologia cardíaca ('Anormal')

Raw data - Análise preliminar (Sumários)




	Missing Values	Percentage of Total Values
Peso	318	1.78
IMC	4727	26.45
Atendimento	983	5.50
DN	1376	7.70
Idade	1496	8.37
Convenio	5304	29.68
Pulsos	1198	6.70
SBP	7730	43.25
DBP	7740	43.31
Result SBP-DBP	1713	9.58
Patologia	1168	6.53
B2	1179	6.60
Sopro	1167	6.53
FC	2041	11.42
HDA1	5414	30.29
HDA2	17221	96.35
Sexo	4	0.02
Motivo1	1097	6.14
Motivo2	4778	26.73

Raw data - Análise preliminar (Sumários)



Raw data - Análise preliminar (Pair Plot)

- **Ruído e Erros de Input:**
 - Raw data é severamente afetada por ruído e erros de registo.
- **Outliers Fisicamente Impossíveis:**
 - Presença de valores extremos que violam a lógica biológica
 - E.g.s Alturas registadas como zero, Pesos com valores negativos, Índices de Massa Corporal (IMC) na ordem dos 600-800, etc...
- **Ofuscamento de Padrões:**
 - Com as 'distorções' presentes, torna-se impossível estabelecer relações lineares claras ou padrões discerníveis entre a maioria das features.
- **Exceção:**
 - Apenas a relação entre Altura e Peso demonstra uma tendência visível, apesar da forte interferência do ruído.



Raw data - Análise preliminar (Histogramas)







- **Ruído em Variáveis Numéricas:**

- Distribuições distorcidas pela presença de ruído, manifestado em "caudas longas" e picos isolados.
- Este ruído é causado por: valores em falta, incorretos ou fisicamente impossíveis.




- **Variáveis Categóricas:**

- Várias variáveis apresentam um número excessivo de categorias únicas, dificultando a generalização.
- Identificação e remoção de features sem valor preditivo (Convénio, Atendimento e DN).
- Vários valores inconsistentes (i.e. valores que representam a mesma coisa mas tem valores 'finais' diferentes)
 - E.g. Sexo M e Masculino representam tudo.





Raw data - Análise preliminar (Histogramas)



Raw data - Análise preliminar (Histogramas)




Raw data - Análise preliminar (Histogramas)



Raw data - Análise preliminar (**Boxplot**)

- **Inconsistências nas target features:** nos labels da classe, têm misturado termos como 'anormal' vs. 'Anormal' e 'Normais' vs. 'Normal'.
- **Valores Fisicamente Impossíveis:** os gráficos confirmam a presença de dados que quebram limites biológicos, incluindo registros de idades e pesos negativos.
- **Outliers Extremos:** foram detetados valores de IMC e Systolic Blood Pressure (SBP) excessivamente altos, ultrapassando os limites fisiológicos aceitáveis.
- **Exceção Visual:** a variável 'Altura' destacou-se por ser a única característica que não apresentou outliers visíveis.





Raw data - Análise preliminar (Boxplot)





Raw data - Análise preliminar (**Medidas dispersão**)

- **Avaliação de Métricas de Dispersão:** análise baseada na Amplitude, Intervalo Interquartil (IQR), Desvio Padrão e Coeficiente de Variação.
- **Discrepância entre Métricas:**
 - Métricas Robustas (IQR): Indicam que a porção central dos dados encontra-se dentro de limites clínicos plausíveis.
 - Métricas Sensíveis (Amplitude e Desvio Padrão): Apresentam-se desproporcionais em variáveis como IMC, Peso e Idade.
- **Variabilidade Artificial:** A elevada variância não reflete diversidade biológica, mas sim erros específicos e valores impossíveis (ex: idades negativas e IMC extremo).
- **Conclusão para o Pré-processamento:** A utilização da média ou desvio padrão para normalização seria enganosa, impondo a necessidade de técnicas de scaling robustas ou tratamento de outliers.

Raw data - Análise preliminar (Medidas dispersão)









Raw data - Análise preliminar (Medidas dispersão)



Raw data - Análise preliminar (**Densidade**)


- **Distorção nos Gráficos de Densidade:** A análise revelou que as distribuições estão severamente distorcidas pela presença de outliers extremos.
- **Picos:** A extensão artificial da escala de valores (causada, por exemplo, por idades negativas ou IMC > 600) forçou a distribuição real da população a comprimir-se num "pico estreito".
- **Ocultação de Padrões:** Estes picos ofuscam as variações significativas entre as classes 'Normal' e 'Anormal', tornando impossível distinguir as categorias.
- **Conclusão:** Os resultados reforçam a necessidade de remover valores impossíveis antes de tentar qualquer standardização ou análise probabilística fiável.

Raw data - Análise preliminar (Densidade)






Raw data - Análise preliminar (Matriz de correlação)

- **Relação linear entre features numéricas:**
 - Com a matriz de correlação foi possível estabelecer que as três correlações positivas mais impactantes ocorrem entre os pares: (Peso, Altura), (SBP, DBP) e (Idade, Peso)
 - Estas relações lineares parecem ser clinicamente válidas.
- É importante notar que foi refeita a matriz de correlação após o passo de pré-processamento, e com isso conclui que os coeficientes de correlação tiveram uma melhoria





Raw data - Análise preliminar (Pair plot correlação)



Raw data - Análise preliminar (Stacked bar chart)

- **Análise:** Para analisar as associações entre features não numéricas e a target feature utilizei stacked bar charts.
- **Principais Discriminadores:** As features 'Sopro' e 'B2' destacaram-se como os indicadores mais significativos para distinguir entre as classes 'Normal' e 'Anormal'.
- **Baixo Impacto do Género:** A variável 'Sexo' demonstrou ter uma influência negligenciável no diagnóstico da patologia.
- **Problema de Alta Cardinalidade:** As variáveis 'Motivo1' e 'Motivo2' apresentam um número excessivo de categorias, dificultando a identificação de padrões sem um agrupamento prévio dos dados.

Raw data - Análise preliminar (Stacked bar chart)



Raw data - Análise preliminar (**Boxplots**)

- **Análise:** Utilização de boxplots para examinar as dependências entre variáveis categóricas e numéricas.
- **Sobreposição de Distribuições:** As visualizações revelaram uma sobreposição significativa nas distribuições numéricas entre os diferentes grupos categóricos.
- **Ausência de Separação Linear:** Conclui-se que as variáveis categóricas, isoladamente, não impõem uma separação clara ou uma relação linear distinta sobre os dados numéricos.

Raw data – Mudanças necessárias na raw data

- **Remoção de features Irrelevantes:** Eliminar features não preditivas, como ID's e datas de visita.
- **Filtragem Etária:** Excluir registos fora do intervalo [2, 19].
- **Consistência Clínica e Correção de Erros:** Remover registos que contêm valores fisicamente impossíveis (ex: altura zero, pesos negativos).
- **Padronização de Rótulos:** Unificar valores categóricos inconsistentes que representam o mesmo conceito (ex: "M" vs. "Masculino").
- **Tratamento de Missing Values**
- **Gestão de Outliers**
- **Feature Transformation/Engenering :** Aplicar standardização, generalizar categorias (intervalos de idade) e construir novas variáveis.

Preprocessing


1. **Remoção de colunas irrelevantes** (IDs, datas administrativas) e aplicação de **filtro etário estrito** (intervalo [2, 19] anos).
 - Redução de **17.753** para **12.384 registros**.
2. **Eliminação de valores fisicamente impossíveis** (ex: pesos negativos, idade negativa) e **padronização de etiquetas categóricas inconsistentes**.
 - Recálculo matemático de variáveis derivadas (IMC e PPA) usando os valores limpos das variáveis Peso/Altura e SBP/DPB respetivamente.
3. **Estratégia Híbrida para Missing Values:**
 - **Imputação:** Aplicada quando a ausência tem significado clínico (ex: sem registo de 'Sopro' assume-se 'Ausente').
 - **Remoção:** Exclusão de linhas quando faltam métricas críticas (Peso, Altura, BP) essenciais para os modelos.
4. **Gestão de Outliers:**
 - Remoção de ruído (valores inválidos), mas preservação de outliers estatísticos que representam casos biológicos extremos, mas plausíveis.
5. **Resultado Final:** dataset com 6.293 registros e 0 valores nulos, pronto para modelação.

Preprocessing – (Sumários)

- **Redução Significativa de Volume:** O dataset passou de **17.873** para **6.293 registros** (mantendo 21 features), refletindo o rigor da limpeza aplicada para garantir a qualidade dos dados.
- **Integridade dos Dados:** Obtenção de um dataset 100% completo (0 valores nulos).
- **Distribuição da Target Feature:** A classe mantém-se desequilibrada, refletindo a realidade clínica:
 - **Normal:** 4.193 casos.
 - **Anormal:** 2.190 casos.

Preprocessing – (Sumários)


```
RangeIndex: 6293 entries, 0 to 6292
Data columns (total 21 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   Peso                                  6293 non-null   float64
 1   Altura                               6293 non-null   int64
 2   IMC                                   6293 non-null   float64
 3   Idade                                6293 non-null   int64
 4   Pulsos                               6293 non-null   object
 5   SBP                                   6293 non-null   float64
 6   DBP                                   6293 non-null   float64
 7   Result SBP-DBP                       6293 non-null   object
 8   B2                                    6293 non-null   object
 9   Sopro                                 6293 non-null   object
10   FC                                    6293 non-null   float64
11   HDA1                                 6293 non-null   object
12   HDA2                                 6293 non-null   object
13   Sexo                                 6293 non-null   object
14   Motivo1                              6293 non-null   object
15   Motivo2                              6293 non-null   object
16   Intervalo Idade                      6293 non-null   object
17   Percentil IMC                        6293 non-null   object
18   Systolic Blood Pressure (SBP)         6293 non-null   object
19   Diastolic Blood Pressure (DBP)        6293 non-null   object
20   Patologia                             6293 non-null   object
dtypes: float64(5), int64(2), object(14)
```




Preprocessing – (Pair plot)

- **Validação Visual da ‘Limpeza’:** A comparação direta com a raw data revela que o "ruído caótico" foi eliminado, sendo substituído por tendências fisiológicas coerentes.
- **Emergência de Correlações:** Ao contrário da dispersão anterior, surgem agora correlações fortes e visíveis entre as variáveis.
- **Consistência Clínica:**
 - **Pressão Arterial:** Relação linear clara entre a Pressão Sistólica e Diastólica.
 - **Crescimento Pediátrico:** Confirmação das tendências de desenvolvimento esperadas, onde a Altura e o Peso aumentam proporcionalmente com a Idade.







RAW DATA





PREPROCESSED DATA

Preprocessing – (Histogramas)





- **Melhoria na Distribuição dos Dados:** Eliminação de picos artificiais causados pelo ruído, resultando em dados com uma aparência "mais suave" e contínua.
- **Recuperação de Padrões Naturais:** A comparação visual comprova a transformação de dados caóticos numa curva natural e bem definida, validando a limpeza efetuada.
- **Otimização de Variáveis Categóricas:** Sucesso na redução da cardinalidade, resultando em categorias mais limpas, organizadas e com maior valor interpretativo.



RAW DATA





PREPROCESSED DATA





RAW DATA





PREPROCESSED DATA



RAW DATA



PREPROCESSED DATA




RAW DATA

PREPROCESSED DATA


Preprocessing – (Boxplots)

- **Restauração da Escala Natural:** A eliminação de outliers impossíveis corrigiu a distorção visual, permitindo observar a verdadeira dispersão dos dados.
- **Resolução da Compressão de Dados:** Ao contrário da raw data, onde os outliers comprimiam as distribuições em, os dados pre-processados revelam estruturas claras.
- **Validação Biológica:** Os Intervalos Interquartis (IQR) e as medianas situam-se agora dentro de limites clínicos plausíveis (ex: IMC e Peso em intervalos realistas)

RAW DATA







PREPROCESSED DATA





Preprocessing – (Medidas dispersão)

- **Estabilização das Métricas:** Observa-se uma redução e estabilização geral nos valores das medidas de dispersão em comparação com a raw data.
- **Eliminação da Distorção Visual:** O efeito de "compressão", que anteriormente ocultava a distribuição real dos dados devido a outliers extremos, foi resolvido.
- **Correção da Inflação Estatística:** As barras de Amplitude e Desvio Padrão deixaram de estar artificialmente inflacionadas por erros de input.
- **Visão Realista:** As métricas refletem agora a verdadeira variabilidade biológica dos dados, permitindo uma análise fiável





RAW DATA





PREPROCESSED DATA



RAW DATA



PREPROCESSED DATA







RAW DATA

PREPROCESSED DATA



Preprocessing – (Densidade)

- **Resolução da Compressão Visual:** A remoção de outliers eliminou a compressão artificial dos dados, substituindo os "picos estreitos" e não informativos por curvas de densidade suaves e contínuas.
- **Revelação da Estrutura Real:** A expansão correta ao longo do eixo X permite, pela primeira vez, analisar a verdadeira assimetria (skewness) da distribuição da população.
- **Distinção entre Classes:** Torna-se possível identificar as variações subtis e padrões distintos entre os grupos "Normal" e "Anormal", que estavam anteriormente ocultos pelo ruído.





RAW DATA





PREPROCESSED DATA



RAW DATA



PREPROCESSED DATA





RAW DATA

PREPROCESSED DATA


Preprocessing – (Matriz de correlação)

- **Melhoria coeficientes:** A matriz processada exibe um aumento marcado na força e definição das dependências entre variáveis em comparação com a raw data.
- **Eliminação de Distorções Lineares:** A remoção de valores extremos (como Altura=0 ou idades negativas) permitiu capturar a verdadeira linearidade fisiológica, anteriormente distorcida.
- **Principais Correlações Identificadas:** 'Peso'/'Altura', 'Idade'/'Peso' e 'Altura'/'Idade'.
 - Relações já existentes foram reforçadas (ex: Peso/Altura).
 - A relação crítica entre 'Altura' e 'Idade' foi desmascarada, tornando-se visível apenas após a eliminação do ruído que a ofuscava.








RAW DATA



PREPROCESSED DATA

Preprocessing - (Pair plot correlação)



Preprocessing – (Stacked bar chart)

- **Análise:** Para analisar as associações entre features não numéricas e a target feature utilizei stacked bar charts.
- **Discriminadores Críticos:** As variáveis 'Sopro' e 'B2' confirmam-se como os preditores mais fortes, apresentando uma correlação quase perfeita entre a presença de sons anormais e a classe 'Anormal'.
- **Valor das Novas Variáveis:**
 - **Feature engineering revelou-se eficaz:** as categorias criadas para a Pressão Arterial mostram uma tendência clara onde pacientes classificados como 'Hipertensos' têm uma representação desproporcional no grupo com patologia.
- **Fator Não-Discriminante:** A variável 'Sexo' mantém uma distribuição equilibrada entre as classes, confirmando que o género não é um discriminador primário para estas patologias cardíacas.

Preprocessing - (Boxplots)

- **Análise:** Utilização de boxplots para examinar as dependências entre variáveis categóricas e numéricas.
- **Validação de Consistência Biológica:** A análise confirma que os dados respeitam a fisiologia real. Os gráficos por 'Intervalo de Idade' mostram um aumento gradual (stepwise) na 'Altura' e 'Peso', refletindo as tendências naturais de crescimento.
- **Comportamento da Target feature('Patologia'):**
 - Classe 'Anormal': Exibe uma dispersão mais ampla e medianas superiores em métricas fisiológicas críticas, como a Pressão Arterial Sistólica (SBP).
- **Conclusão:** Estes padrões confirmam que as variáveis numéricas fisiológicas são discriminadores relevantes para distinguir entre pacientes saudáveis e com patologia.

Análise

- A análise foi dividida em três partes:
 - Bivariate analysis (correlations, regression)
 - Multivariate analysis
 - Modelos preditivos

Análise - Bivariate analysis (Correlação)

1. Correlação

- **Principais Correlações (Matriz Slide 47):** Os pares com maior correlação positiva são **Altura/Idade**, **Peso/Altura** e **Peso/Idade**
- Confirma-se que a principal fonte de variância nos dados numéricos é impulsionada pelo **estágio de crescimento** do paciente

Análise - Bivariate analysis (Regressão linear)

1. Regressão Linear

- **Definição dos Modelos:** Aplicação de Regressão Linear Simples baseada em causalidade biológica (ex: a Idade determina a Altura)
- **Métricas de Avaliação:**
 - **R^2 (R-squared):** Mede a percentagem de variância explicada pelo preditor.
 - **Coeficiente:** Quantifica a magnitude da relação (aumento esperado na variável alvo).
- **Resultados Principais:**
 - Os modelos Altura/Idade e Peso/Altura exibiram o maior poder preditivo (**alto R^2**).
 - Os coeficientes positivos validam que as medidas antropométricas aumentam proporcionalmente com o envelhecimento.

X é a variável independente (**Predictor**)

Y é a variável dependente (**Target**)

```
--- Analisando: Altura (Y) vs Idade (X) ---  
R-squared: 0.8695  
Coeficiente: 5.3480
```

```
--- Analisando: Peso (Y) vs Altura (X) ---  
R-squared: 0.7730  
Coeficiente: 0.6338
```

```
--- Analisando: Peso (Y) vs Idade (X) ---  
R-squared: 0.6553  
Coeficiente: 3.3469
```

```
--- Analisando: IMC (Y) vs Peso (X) ---  
R-squared: 0.5995  
Coeficiente: 0.1932
```

Análise - Multivariate analysis (Logistic regression)


- **Objetivo:** Avaliar a influência independente de cada feature na target feature ('Patologia').
- **Metodologia:** Utilização de um modelo de Regressão Logística, selecionado pela sua aptidão para tarefas de classificação binária (Normal vs. Anormal).
- **Preparação dos Dados:** Aplicação de Standardization (para variáveis numéricas) e One-Hot Encoding (para categóricas) para garantir uma avaliação justa da importância das variáveis.

Coeficientes LR para ‘Normal’

Sopro_Ausente	1.325904
B2_Normal	0.362184
Motivo1_Triagem Cardiológica	0.217315
Motivo2_Cardiopatia congenica	0.151848
Motivo2_Presença de Sopro	0.150262



Coeficientes LR para ‘Anormal’

IMC	-0.244498
FC	-0.292838
Motivo1_Cardiopatia	-0.293263
B2_Hyperphonic	-0.513155
Sopro_Sistólico	-1.320056



Análise - Multivariate analysis (Mutual Information)

- Utilização de Mutual Information como métrica complementar para validar os coeficientes obtidos na Regressão Logística.
- A análise foi realizada sobre os mesmos dados standardizados e codificados (one-hot encoded) para garantir a integridade da comparação.
- **Resultados:** Observou-se que as features com os maiores scores de Mutual Information correspondem exatamente àquelas com os coeficientes de regressão mais significativos (ver slide seguinte).
 - Esta convergência entre métodos diferentes fornece evidência sólida de que estas variáveis são, efetivamente, os principais determinantes da classe alvo.



Análise - Multivariate analysis (K-Means Clustering)

- **Objetivo da Análise:** Aplicação de K-Means Clustering em variáveis numéricas standardizadas para verificar se os dados se segregam naturalmente em grupos correspondentes às classes alvo ('Normal' vs. 'Anormal').
- **Resultado do Agrupamento:** A análise revelou que os clusters formados não se alinham perfeitamente com as categorias patológicas.
- **Interpretação Clínica:** A discrepância indica que a doença não se manifesta exclusivamente através de alterações em variáveis numéricas (como Pressão Arterial ou IMC).
- **Conclusão Final:** As variáveis categóricas contém informação clínica que é essencial para uma distinção precisa, reforçando as descobertas anteriores de Feature Importance.

Análise – Modelos preditivos (Overview)

- **Seleção de Algoritmos:**

- **Decision Trees:** Escolhidas pela interpretabilidade baseada em regras.
- **Support Vector Machines (SVM):** Para encontrar hiperplanos ótimos em espaços de alta dimensão.
- **Bayesian Networks:** Para incorporar raciocínio probabilístico.

- **Pipeline de Preparação:**

- Standardization aplicada para normalizar escalas numéricas.
- One-Hot Encoding utilizado para converter variáveis categóricas em formatos numéricos.

- **Divisão dos Dados:**





- 80% Treino / 20% Teste, mantendo o desequilíbrio natural das classes.
- Não apliquei técnicas de balanceamento artificial (como SMOTE ou undersampling) , porque quis manter a distribuição da população e evitar enviesar as estimativas de probabilidade, o que poderia gerar altas taxas de falsos positivos (indesejável num contexto de triagem/screening).

Análise – Modelos preditivos (Overview)

- **Otimização de Hiperparâmetros:** Teste comparativo de duas configurações distintas por algoritmo para avaliar o desempenho sob diferentes condições de parâmetros.
- **Validação de Estabilidade:** Cálculo de Cross-Validation scores para verificar a robustez e consistência dos resultados antes da avaliação final.
- **Análise Visual:** Utilização de Matrizes de Confusão e Curvas ROC/PR para uma interpretação gráfica do desempenho.
- **Métricas performance:** Análise detalhada através de Classification Reports (focando em Precision, Recall e F1-Score) para avaliar a eficácia tanto na classe 'Normal' como na 'Anormal'.





Análise – Modelos preditivos (DT performance)

- **Desempenho Geral:** Ambos os modelos de Decision Tree apresentaram resultados positivos e consistentes.
- **Modelo Vencedor:** O **Modelo 1** destacou-se com uma ligeira vantagem de desempenho sobre o Modelo 2.
- **Prevenção de Overfitting:** A análise demonstra que a profundidade reduzida do Modelo 1 foi crucial para evitar o overfitting.
- **Capacidade de Generalização:** Ao limitar a complexidade da árvore, o modelo permanece genérico o suficiente para classificar com precisão novos dados de pacientes.







Análise – Modelos preditivos (SVM performance)

- **Modelo Vencedor:** O Modelo 1 (Kernel Polinomial) demonstrou métricas de desempenho superiores em comparação com o Modelo 2 (Kernel Sigmoidal).
 - Os resultados sugerem que a fronteira que separa as patologias 'Normal' e 'Anormal' é melhor aproximada por uma curva polinomial.
- **Eficácia do Mapeamento:** O Kernel Polinomial mapeou com sucesso os dados para um espaço de dimensão superior, onde as classes se tornaram claramente separáveis.
- **Limitação do Sigmoidal:** Embora tente imitar a função de ativação de redes neurais, o Kernel Sigmoidal revelou dificuldades em modelar este espaço de características específico.



Análise – Modelos preditivos (**Bayesian Net. performance**)

- **Comparação modelos:** Ambos os modelos alcançaram métricas de performance praticamente idênticas, indicando uma dificuldade do algoritmo em melhorar com o hyperparameter tuning.
- **Limitações das Assunções Probabilísticas:** A estagnação sugere que as premissas de independência entre as features podem não se verificar totalmente neste dataset clínico.
- **Modelo Vencedor:** O Modelo 1 foi tecnicamente selecionado como o melhor entre os dois.



Análise – Modelos preditivos (Comparação geral)

- **Ranking Inferior (BN):** A Bayesian Network demonstrou o menor desempenho preditivo entre os três algoritmos testados.
- **Liderança Partilhada:** O Support Vector Machine (SVM) e a Decision Tree (DT) atingiram o nível superior, apresentando resultados semelhantes nas métricas chave (Accuracy, Recall e F1-Score).
- **Conclusão:** Devido à proximidade dos resultados, não é possível declarar um vencedor absoluto baseando-se apenas nos scores de classificação.
- **Limitações do Estudo:** Fatores como custo computacional e tempo de inferência, que poderiam servir como critérios de desempate, não foram avaliados no âmbito deste relatório.

Conclusões

- **Qualidade dos dados é crítica:** O projeto demonstrou claramente que a qualidade dos dados é o fator determinante mais significativo para o desempenho de um modelo preditivo.
- **Importância de pré-processamento:** A transição da raw data para os preprocessed provou que a remoção de ruído é obrigatória para revelar as verdadeiras dependências estatísticas.
- **Contextualização:** A compreensão contextual das variáveis fisiológicas foi a única forma de validar eficazmente as hipóteses e garantir a fiabilidade clínica dos modelos finais. Isto demonstrou que a contextualização no tema é essencial para qualquer tarefa que envolva a criação de modelos preditivos.

Repositório

- <https://github.com/RS181/Data-Mining-I/tree/main/Assignment>